

2023编译技术实验文法定义及相关说明

零、概要

SysY 语言是实验所完成的编译器的源语言，是 C 语言的一个子集。该文件中有且仅有一个名为 main 的主函数定义，还可以包含若干全局变量声明、常量声明和其他函数定义。SysY 语言支持 **int 类型** 和元素为 int 类型且按行优先存储的**多维数组类型**，其中 int 型整数为 32 位有符号数；**const** 修饰符用于声明常量。

SysY 语言通过 getint 与 printf 函数完成 I/O 交互，函数用法已在文法中给出，需要同学们自己实现。

- **函数**：函数可以带参数也可以不带参数，参数的类型可以是 int 或者数组类型；函数可以返回 int 类型的值，或者不返回值(即声明为 void 类型)。当参数为 int 时，按值传递；而参数为数组类型时，实际传递的是数组的起始地址，并且形参只有第一维的长度可以空缺。函数体由若干变量声明和语句组成。
- **变量/常量声明**：可以在一个变量/常量声明语句中声明多个变量或常量，声明时可以带初始化表达式。所有变量/常量要求先定义再使用。在函数外声明的为全局变量/常量，在函数内声明的为局部变量/常量。
- **语句**：语句包括赋值语句、表达式语句(表达式可以为空)、语句块、if 语句、for 语句、break 语句、continue 语句、return 语句。语句块中可以包含若干变量声明和语句。
- **表达式**：支持基本的算术运算 (+、-、*、/、%)、关系运算 (==、!=、<、>、<=、>=) 和逻辑运算 (!、&&、||)，非 0 表示真、0 表示假，而关系运算或逻辑运算的结果用 1 表示真、0 表示假。**算符的优先级和结合性以及计算规则(含逻辑运算的“短路计算”)与 C 语言一致。**

一、输入输出函数定义

```
<InStmt> → <LVal> = 'getint'('(')'  
<OutStmt> → 'printf'('('<FormatString>{,<Exp>}')'
```

其中，**FormatString** 为格式字符串终结符，其规范如下：为了与 clang 评测结果一致，(<NormalChar> 的转义字符有且仅有 '\n'，其余情况，" 单独出现是不合法的)

```
<FormatChar> → %d  
<NormalChar> → 十进制编码为 32, 33, 40-126 的 ASCII 字符，'\'（编码 92）出现当且仅当为 '\n'  
<Char> → <FormatChar> | <NormalChar>  
<FormatString> → '{<Char>}'
```

格式字符串中**仅可能会出现一种转义字符 \n**，用以标注此处换行，其他转义情况无需考虑。

对应的，语句 <Stmt> 的右侧需要添加上述输入输出语句，即

```
<Stmt> → ...  
| <LVal> = 'getint'('(')';  
| 'printf'('('<FormatString>{,<Exp>}')';
```

如果希望在 C 语言中测试测试程序，只需要将 getint 加入函数声明即可，示例如下：

```
int getint(){
    int n;
    scanf("%d",&n);
    return n;
}
```

二、文法及测试程序覆盖要求

1. 覆盖要求

测试程序是为了测试编译器而编写的符合文法规则的SysY语言程序，在实验的“文法解读作业”中需要同学们编写测试程序。测试程序需覆盖文法中**所有的语法规则**（即每一条推导规则的每一个候选项都要被覆盖），并**满足文法的语义约束**（换言之，测试程序应该是正确的）。在下一节中，文法正文中以**注释形式**给出需要覆盖的情况。

2. 文法

SysY 语言的文法采用扩展的 Backus 范式（EBNF，Extended Backus-Naur Form）表示，其中：

- 符号[...]表示方括号内包含的为可选项
- 符号{...}表示花括号内包含的为可重复 0 次或多次的项
- 终结符或者是由单引号括起的串，或者是 Ident、InstConst 这样的记号

SysY 语言的文法表示如下，其中 CompUnit 为开始符号：

重要：建议同时对照文法第三部分的语义约束。

编译单元 **CompUnit** → {Decl} {FuncDef} MainFuncDef // 1.是否存在Decl 2.是否存在FuncDef

声明 **Decl** → ConstDecl | VarDecl // 覆盖两种声明

常量声明 **ConstDecl** → 'const' BType ConstDef { ',' ConstDef } ';' // 1.花括号内重复0次 2.花括号内重复多次

基本类型 **BType** → 'int' // 存在即可

常数定义 **ConstDef** → Ident { '[' ConstExp ']' } '=' ConstInitVal // 包含普通变量、一维数组、二维数组共三种情况

常量初值 **ConstInitVal** → ConstExp

| '{' [ConstInitVal { ',' ConstInitVal }] '}' // 1.常表达式初值 2.一维数组初值 3.二维数组初值

变量声明 **VarDecl** → BType VarDef { ',' VarDef } ';' // 1.花括号内重复0次 2.花括号内重复多次

变量定义 **VarDef** → Ident { '[' ConstExp ']' } // 包含普通变量、一维数组、二维数组定义

| Ident { '[' ConstExp ']' } '=' InitVal

变量初值 **InitVal** → Exp | '{' [InitVal { ',' InitVal }] '}' // 1.表达式初值 2.一维数组初值 3.二维数组初值

函数定义 **FuncDef** → FuncType Ident '(' [FuncFParams] ')' Block // 1.无形参 2.有形参

主函数定义 **MainFuncDef** → 'int' 'main' '(' ')' Block // 存在main函数

函数类型 **FuncType** → 'void' | 'int' // 覆盖两种类型的函数

函数形参表 **FuncFParams** → FuncFParam { ',' FuncFParam } // 1.花括号内重复0次 2.花括号内重复多次

函数形参 FuncFParam → BType Ident '[' ']' { '[' ConstExp ']' } // 1.普通变量2.一维数组变量 3.二维数组变量

语句块 Block → '{' { BlockItem } '}' // 1.花括号内重复0次 2.花括号内重复多次

语句块项 BlockItem → Decl | Stmt // 覆盖两种语句块项

语句 Stmt → LVal '=' Exp ';' // 每种类型的语句都要覆盖

| [Exp] ';' //有无Exp两种情况

| Block

| 'if' '(' Cond ')' Stmt ['else' Stmt] // 1.有else 2.无else

| 'for' '(' [ForStmt] ';' [Cond] ';' [ForStmt] ')' Stmt // 1. 无缺省 2. 缺省第一个ForStmt 3. 缺省Cond 4. 缺省第二个ForStmt

| 'break' ';' | 'continue' ';' ;

| 'return' [Exp] ';' // 1.有Exp 2.无Exp

| LVal '=' 'getint' '(' ')' ';' ;

| 'printf' '(' FormatString{','Exp}'') ';' // 1.有Exp 2.无Exp

语句 ForStmt → LVal '=' Exp // 存在即可

表达式 Exp → AddExp 注: SysY 表达式是int 型表达式 // 存在即可

条件表达式 Cond → LOrExp // 存在即可

左值表达式 LVal → Ident { '[' Exp ']' } //1.普通变量 2.一维数组 3.二维数组

基本表达式 PrimaryExp → '(' Exp ')' | LVal | Number // 三种情况均需覆盖

数值 Number → IntConst // 存在即可

一元表达式 UnaryExp → PrimaryExp | Ident '(' [FuncRParams] ')' // 3种情况均需覆盖,函数调用也需要覆盖FuncRParams的不同情况

| UnaryOp UnaryExp // 存在即可

单目运算符 UnaryOp → '+' | '-' | '!' 注: '!'仅出现在条件表达式中 // 三种均需覆盖

函数实参表 FuncRParams → Exp { ',' Exp } // 1.花括号内重复0次 2.花括号内重复多次 3.Exp需要覆盖数组传参和部分数组传参

乘除模表达式 MulExp → UnaryExp | MulExp ('*' | '/' | '%') UnaryExp // 1.UnaryExp 2.* 3./ 4.% 均需覆盖

加减表达式 $\text{AddExp} \rightarrow \text{MulExp} \mid \text{AddExp} ('+' \mid '-') \text{MulExp} //$ 1. MulExp 2. $+$ 需覆盖 3. $-$ 需覆盖

关系表达式 $\text{RelExp} \rightarrow \text{AddExp} \mid \text{RelExp} ('<' \mid '>' \mid '<=' \mid '>=') \text{AddExp} //$ 1. AddExp 2. $<$ 3. $>$ 4. $<=$ 5. $>=$ 均需覆盖

相等性表达式 $\text{EqExp} \rightarrow \text{RelExp} \mid \text{EqExp} ('==' \mid '!=') \text{RelExp} //$ 1. RelExp 2. $==$ 3. $!=$ 均需覆盖

逻辑与表达式 $\text{LAndExp} \rightarrow \text{EqExp} \mid \text{LAndExp} ' \&\&' \text{EqExp} //$ 1. EqExp 2. $\&\&$ 均需覆盖

逻辑或表达式 $\text{LOrExp} \rightarrow \text{LAndExp} \mid \text{LOrExp} ' \mid\mid ' \text{LAndExp} //$ 1. LAndExp 2. $\mid\mid$ 均需覆盖

常量表达式 $\text{ConstExp} \rightarrow \text{AddExp}$ 注: 使用的 **Ident** 必须是常量 $//$ 存在即可

标识符 **Ident**:

```
identifier → identifier-nondigit  
           | identifier identifier-nondigit  
           | identifier digit
```

数值常量:

```
integer-const → decimal-const | 0  
decimal-const → nonzero-digit | decimal-const digit
```

注: 标识符和数值常量的具体说明, 详见下节内容。

3. 终结符特征

(1) 标识符 **Ident**

SysY 语言中标识符 **Ident** 的规范如下 (**identifier**):

```
identifier → identifier-nondigit  
           | identifier identifier-nondigit  
           | identifier digit
```

其中, **identifier-nondigit** 为下划线或大小写字母, **digit** 为 0 到 9 的数字。

注: 请参考 ISO/IEC 9899 <http://www.open-std.org/jtc1/sc22/wg14/www/docs/n1124.pdf> 第 51 页关于标识符的定义 **同名标识符** 的约定:

- 全局变量 (常量) 和局部变量 (常量) 的作用域可以重叠, 重叠部分局部变量 (常量) 优先
- 同名局部变量的作用域不能重叠, 即同一个 Block 内不能有同名的标识符 (常量/变量)
- 在不同的作用域下, SysY 语言中变量 (常量) 名可以与函数名相同

```
// 合法样例
int main() {
    int a = 0;
    {
        int a = 1;
        printf("%d",a); // 输出 1
    }
    return 0;
}
```

```
// 非法样例
int main() {
    int a = 0;
    {
        int a = 1;
        int a = 2; // 非法!
    }
    return 0;
}
```

(2) 注释

SysY 语言中注释的规范与 C 语言一致，如下：

单行注释：以序列 `/**` 开始，直到换行符结束，不包括换行符。

多行注释：以序列 `/*` 开始，直到第一次出现 `*/` 时结束，包括结束处 `*/`。

注：请参考 ISO/IEC 9899 <http://www.open-std.org/jtc1/sc22/wg14/www/docs/n1124.pdf> 第 66 页关于注释的定义

(3) 数值常量

SysY 语言中数值常量可以是整型数 **IntConst**，其规范如下（对应 `integer-const`）：

整型常量 `integer-const` \rightarrow `decimal-const` | 0

`decimal-const` \rightarrow `nonzero-digit` | `decimal-const digit`

`nonzero-digit` 为 1 至 9 的数字。

注：请参考 ISO/IEC 9899 <http://www.open-std.org/jtc1/sc22/wg14/www/docs/n1124.pdf> 第 54 页关于整型常量的定义，在此基础上忽略所有后缀。

4. 难度分级

为了更好的帮助同学们完成编译器的设计，课程组今年将题目难度做了区分。难度等级分为三级：A、B、C，难度依次递减。下文将对难度等级进行详细介绍：

- C：最简单的等级，重点考察编译器的基础设计。
- B：在 C 级的基础上，**新增**数组，包括数组定义，数组元素的使用、数组传参和部分传参等。部分传参样例：

```
void func(int a[]) {
    //...
}
int main() {
    int arr[2][2] = {{1,2},{3,4}};
    func(arr[1]);
    return 0;
}
```

- A: 在 B 级的基础上，**新增**复杂条件的运算和判断，要遵守短路求值的规则。

短路求值样例：

```
int global_var = 0;
int func() {
    global_var = global_var + 1;
    return 1;
}
int main() {
    if (0 && func()){
        ;
    }
    printf("%d",global_var); // 输出 0
    if (1 || func()) {
        ;
    }
    printf("%d",global_var); // 输出 0
    return 0;
}
```

注：低级难度的样例不包含高级难度样例新增的规则。

三、语义约束

符合上述文法的程序集合是合法的 SysY 语言程序集合的超集。下面进一步给出 SysY 语言的语义约束。

简化文法约束

- 文法中多维数组的维度至多为 2 维。
- 多维数组的初始化中，子维度的初始化一定会加入 '{', '}', 并且花括号内元素数量与维度一定完全一致，例如二维数组初始化为：a[2][2]={1,2},{3,4}。

I/O语句

- 输入语句以函数调用的形式出现，对应函数声明如下。虽然输入语句以函数调用形式出现，**getint仍被识别为关键字而不是标识符**，在词法分析阶段和语法分析阶段需要注意。

```
int getint();
```

- 与 C 语言中的 printf 类似，输出语句中，格式字符将被替换为对应标识符，普通字符原样输出。
- printf默认不换行

编译单元 CompUnit

编译单元 CompUnit \rightarrow {Decl} {FuncDef} MainFuncDef

声明 Decl \rightarrow ConstDecl | VarDecl

注意:

1. CompUnit 的顶层变量/常量声明语句 (对应 Decl)、函数定义 (对应 FuncDef) 都不可以重复定义同名标识符 (Ident), 即便标识符的类型不同也不允许。
2. CompUnit 的变量/常量/函数声明的作用域从该声明处开始到文件结尾。

常数定义 ConstDef

常数定义 ConstDef \rightarrow Ident { '[' ConstExp ']' } '=' ConstInitVal

1. ConstDef 用于定义符号常量。ConstDef 中的 Ident 为常量的标识符, 在 Ident 后、'=' 之前是可选的数组维度和各维长度的定义部分, 在 '=' 之后是初始值。
2. ConstDef 的数组维度和各维长度的定义部分不存在时, 表示定义单个变量。此时 '=' 右边必须是单个初始数值。
3. ConstDef 的数组维度和各维长度的定义部分存在时, 表示定义数组。其语义和 C 语言一致, 比如 [2][8/2] 表示二维数组, 第一到第二维长度分别为 2、4, 每维的下界从 0 编号。ConstDef 中表示各维长度的 ConstExp 都必须能在编译时求值到**非负整数**。

注意: SysY 在声明数组时各维长度都需要显式给出, 而不允许是未知的。

ISO/IEC 9899 <http://www.open-std.org/jtc1/sc22/wg14/www/docs/n1124.pdf> 第 125 页 6.7.8 节的第 6 点规定如下:

If a designator has the form [constant-expression] then the current object (defined below) shall have array type and the expression shall be an integer constant expression. If the array is of unknown size, any nonnegative value is valid.

4. 当 ConstDef 定义的是数组时, '=' 右边的 ConstInitVal 表示常量初始化器。ConstInitVal 中的 ConstExp 是能在编译时求值的 int 型表达式, 其中可以引用已定义的符号常量。
5. ConstInitVal 初始化器必须是以下情况 (注: int 型初始值可以是 Number, 或者是 int 型常量表达式): 与多维数组中数组维度和各维长度完全对应的初始值, 且必须对数组的每个元素进行显式初始化, 如 {{1,2},{3,4},{5,6}} 为 a[3][2] 的初始值。

变量定义 VarDef

变量定义 VarDef \rightarrow Ident { '[' ConstExp ']' }

| Ident { '[' ConstExp ']' } '=' InitVal

1. VarDef 用于定义变量。当不含有 '=' 和初始值时, 其运行时实际初值未定义。
2. VarDef 的数组维度和各维长度的定义部分不存在时, 表示定义单个变量。存在时, 和 ConstDef 类似, 表示定义多维数组。(参见 ConstDef 的第 2 点)
3. 当 VarDef 含有 '=' 和初始值时, '=' 右边的 InitVal 和 ConstInitVal 的结构要求相同, 唯一不同的是 ConstInitVal 中的表达式是 ConstExp 常量表达式, 而 InitVal 中的表达式可以是当前上下文合法的任何 Exp。

4. VarDef 中表示各维长度的 ConstExp 必须是能求值到**非负整数**，但 InitVal 中的初始值为 Exp，其中可以引用变量，例如下面b的初始化：

```
int a[2][2]={1,2},{3,4};
int b[2][2]={a[0][0],a[0][1]},{a[1][0],a[1][1]};
```

初值 InitVal/ConstInitVal

常量初值 ConstInitVal \rightarrow ConstExp

| '{' [ConstInitVal { ',' ConstInitVal }] '}'

变量初值 InitVal \rightarrow Exp | '{' [InitVal { ',' InitVal }] '}'

1. 全局变量声明中指定的初值表达式必须是常量表达式。
2. 常量或变量声明中指定的初值要与该常量或变量的类型一致如下形式的 VarDef / ConstDef 不满足SysY 语义约束：

```
a[4] = 4
a[2] = {{1,2}, 3}
a = {1,2,3}
```

3. 未显式初始化的局部变量，其值是不确定的；而未显式初始化的全局变量，其（元素）值均被初始化为 0。

函数形参 FuncFParam 与实参

函数形参 FuncFParam \rightarrow BType Ident ['[' ']' { '[' ConstExp ']' }]

1. FuncFParam 定义一个函数的一个形式参数。当 Ident 后面的可选部分存在时，表示数组定义。
2. 当 FuncFParam 为数组定义时，其第一维的长度省去（用方括号[]表示），而后面的各维则需要用表达式指明长度，长度是常量。
3. 函数实参的语法是 Exp。对于 int 类型的参数，遵循按值传递；对于数组类型的参数，则形参接收的是实参数组的地址，并通过地址间接访问实参数组中的元素。
4. 对于多维数组，可以传递其中的一部分到形参数组中。例如，若 int a[4][3], 则 a[1] 是包含三个元素的一维数组，a[1] 可以作为参数传递给类型为 int[] 的形参。
5. 常量数组如 const int arr[3] = {1,2,3}，常量数组 arr **不能**作为参数传入到函数中
6. 函数调用时要保证实参类型和形参类型一致，否则要错误处理。这里的类型一致，是指**地址的维数**要保持一致。例如：


```

void foo(int a[]) { // 形参 a 是一维地址
...
}
int main() {
    int p[2][2] = {{1, 2}, {3, 4}};
    foo(p); // 实参 p 是二维地址，与形参 a 的维数不一致，需进行错误处理
    foo(p[1]); // 实参 p[1] 是一维地址，与形参 a 的维数一致，正确
    foo(p[3]); // 实参 p[3] 是一维地址，但是地址“越界”了，评测样例中不会出现这种情况!!!
...
}

```

函数定义 FuncDef

函数定义 $\text{FuncDef} \rightarrow \text{FuncType Ident '([' FuncFParams ')] Block}$

1. FuncDef 表示函数定义。其中的 FuncType 指明返回类型。当返回类型为 int 时，函数内所有分支都应当含有带有 Exp 的 return 语句。不含有 return 语句的分支的返回值未定义。当返回值类型为 void 时，函数内只能出现不带返回值的 return 语句。
2. FuncDef 中形参列表 (FuncFParams) 的每个形参声明 (FuncFParam) 用于声明 int 类型的参数，或者是元素类型为 int 的多维数组。FuncFParam 的语义参见前文。

语句块 Block

1. Block 表示语句块。语句块会创建作用域，语句块内声明的常量和变量的生存期在该语句块内。
2. 语句块内可以再次定义与语句块外同名的变量或常量（通过 Decl 语句），其作用域从定义处开始到该语句块尾结束，它隐藏语句块外的同名变量或常量。
3. 为了简化学生开发编译器的难度，我们保证评测的样例程序中：有返回值的函数 Block 的最后一句一定会显式的给出 return 语句，否则就当作“无返回语句”的错误处理。
4. main 函数的返回值只能为 0。

语句 Stmt

1. Stmt 中的 if 类型语句遵循就近匹配。
2. 单个 Exp 可以作为 Stmt。Exp 会被求值，所求的值会被丢弃。

左值 LVal

1. LVal 表示具有左值的表达式，可以为变量或者某个数组元素。
2. 当 LVal 表示数组时，方括号个数必须和数组变量的维数相同（即定位到元素）。
3. 当 LVal 表示单个变量时，不能出现后面的方括号。

Exp 与 Cond

1. Exp 在 SysY 中代表 int 型表达式，故它定义为 AddExp；Cond 代表条件表达式，故它定义为 LOrExp。前者的单目运算符中不出现 '!'，后者可以出现。
2. LVal 必须是当前作用域内、该 Exp 语句之前有定义的变量或常量；对于赋值号左边的 LVal 必须是变量。
3. 函数调用形式是 Ident '(' FuncRParams ')', 其中的 FuncRParams 表示实际参数。实际参数的类型和个数必须与 Ident 对应的函数定义的形参完全匹配。
4. SysY 中算符的优先级与结合性与 C 语言一致，在上面的 SysY 文法中已体现出优先级与结合性的定义。

一元表达式 UnaryExp

1. 相邻两个 UnaryOp 不能相同, 如 `int a = ++-i;`, 但是 `int a = +-+i;` 是可行的。
2. UnaryOp 为 '!' 只能出现在条件表达式中。

常量表达式 ConstExp

1. ConstExp -> AddExp 中使用的 ident 必须是常量